

CardioConsult PC V5 EchoBench 技术报告

APA 引用版 · 带图带表 · 生成日期：2026-06-04

技术摘要

CardioConsult PC V5 面向心脏超声教学参考和基层辅助初筛场景。这里的 PC 被定义为可直接接入超声机器或超声工作站的离线分析设备：它可以通过 USB、局域网共享目录、DICOM 工作站导出目录或无线超声软件导出文件读取 PNG、DICOM/DCOM 与超声动图，并在本机输出从大方向到最小病症的结构化疑似诊断文字。V5 在原有 B-mode、Color Doppler、层级标签规则和 Gemma4 4B GGUF 本地报告生成基础上，加入 EchoNet-Dynamic 动态 B-mode 校准层和轻量离线多智能体编排，用于增强 EF/左室收缩功能减低识别、报告安全审计和提交演示透明度。

PC 设备定位：超声机器旁离线分析终端

本报告中的 PC 不是云端后台，也不是仅用于展示的通用桌面软件，而是放置在超声检查室、教学训练室或基层医疗点的本地分析设备。实际工作流中，超声机器或无线超声软件完成采集后，可把 PNG、DICOM/DCOM、cine 或视频导出到 USB、局域网共享目录、DICOM 工作站目录或本机指定文件夹，PC V5 从这些位置读取资料并完成本地预处理、特征提取、规则判断和 Gemma4 4B GGUF 报告生成。

这种定位的目的有三点。第一，敏感图像和授权教学病例不需要上传云端，便于在网络不稳定或隐私要求高的场景中演示。第二，PC 能承担比手机更稳定的批量文件解析、视频抽帧、DICOM 兼容和 GGUF 常驻推理任务，适合作为超声设备旁的离线辅助终端。第三，输出始终限定为医学教学和基层参考，不替代正式超声报告、医师诊断、治疗建议或急诊分诊。

关键结论

- 完整证据场景 60/60 例成功，平均 3.76 秒/例；12 帧代表抽样场景 60/60 例成功，平均 2.56 秒/例。
- 完整证据下 MR F1 为 0.964，AR F1 为 0.700，低 EF F1 为 0.857；MR 与低 EF 已达到较稳定的教学演示水平。

- 12 帧场景下 MR F1 仍为 0.936，但 AR F1 降至 0.326，说明主动脉瓣反流强依赖切面覆盖和彩色多普勒代表帧。
- GGUF 本地生成建议使用常驻 llama-server：冷启动首次 completion 约 8.78 秒，热启动 completion 约 0.49 秒。

完整证据场景：核心指标

完整证据场景使用每例所有可用文件，平均 17.3 个文件/例，最多 33 个文件/例。该场景代表资料相对充分时的系统能力上限。TR 在本批数据中没有阴性样本，因此特异性不能作为有效结论。

标签	n	阳性金标准	准确率	敏感性	特异性	F1
MR (二尖瓣)	60	55	0.933	0.964	0.600	0.964
TR (三尖瓣)	60	60	1.000	1.000	0.000*	1.000
AR (主动脉瓣)	60	29	0.700	0.724	0.677	0.700
低 EF	60	6	0.967	1.000	0.963	0.857
RWMA	60	3	0.967	0.333	1.000	0.500
左房扩大	60	8	0.883	1.000	0.865	0.696




图 1. EchoBench v1 F1: 完整证据与 12 帧代表抽样对比。

12 帧代表抽样：输入受限场景

12 帧场景将每例文件做均匀代表抽样，而不是只取前 12 个文件。该场景更接近现场演示和标准输入上限，但会牺牲部分细粒度病症定位能力。

标签	n	阳性金标准	准确率	敏感性	特异性	F1
MR（二尖瓣）	60	55	0.883	0.927	0.400	0.936
TR（三尖瓣）	60	60	1.000	1.000	0.000*	1.000
AR（主动脉瓣）	60	29	0.517	0.241	0.774	0.326
低 EF	60	6	0.917	0.667	0.944	0.615
RWMA	60	3	0.933	0.333	0.965	0.333
左房扩大	60	8	0.750	0.375	0.808	0.286




图 2. EchoBench v1 准确率：完整证据与 12 帧代表抽样对比。

延迟与本地 GGUF 性能

完整证据场景平均 3.76 秒/例，P95 为 5.51 秒；12 帧场景平均 2.56 秒/例，P95 为 3.20 秒。规则与小模型校准流水线不包含每例完整 GGUF 文本生成。

场景	成功例数	平均秒/例	P50	P90	P95	P99	最大值
完整证据	60/60	3.761	3.311	5.012	5.513	6.704	7.282
12 帧代表抽样	60/60	2.562	2.471	2.796	3.201	3.624	3.680




图 3. EchoBench v1 每例延迟百分位。

GGUF/llama.cpp 指标	结果
GGUF 文件	gemma-4-4b-it-Q4_K_M.gguf
SHA256	519b9793ed6ce0ff530f1b7c96e848e08e49e7af4d57bb97f76215963a54146d
llama.cpp build	b9469
CPU threads	14
prompt processing	37.76 tokens/s
generation	6.19 tokens/s
server 首次 completion	8.775 s
server 热启动 completion	0.492 s

数据、模型与方法

本次主测试集来自授权本地 DICOM/报告时间映射，共 60 个病例。该数据只用于本地授权教育验证，不随代码发布，不作为公开数据集再分发。报告链接标签被用作当前 benchmark 的报告链接金标准，但不是独立多专家盲法复核金标准。

V5 使用 EchoNet-Dynamic 公开数据进行动态 B-mode EF 校准。实际读取 10,030 个心尖四腔 .avi 视频、FileList.csv 中的 EF/ESV/EDV/FPS/帧数/官方 split，以及 VolumeTracings.csv 中的专家左室追踪帧。EchoNet-Dynamic 原论文证明心超视频深度学习可用于逐搏心功能评估 (Ouyang et al., 2020) 。

V5 新增轻量离线多智能体编排：InputAgent 核对输入和相位，FeatureAgent 汇总 B-mode/Doppler/动态图代理特征，DiagnosisAgent 复用层级规则、V4 校准和 V5 EchoNet 校准，ReportAgent 记录规则后备或本地 Gemma4 后端，SafetyAuditAgent 检查教学用途、非医疗器械、非临床诊断和复核/转诊提示。该层不联网、不额外多次调用 Gemma4，也不重复执行图像特征提取；当前本机 rule-only smoke test 中，开启审计 JSON 写入后的诊断阶段平均约 4.1 ms/次，单次自检审计链显示约 8.6 ms，并可把审计 JSON 写入 exports/agent_audit/。

子任务	选中模型	选择依据
EF 回归	HistGradientBoostingRegressor	验证集 MAE/RMSE 优于 Ridge 与 MLP
低 EF 分类	LogisticRegression	验证集 F1 最优，AUC 接近树模型，推理更轻

EchoNet-Dynamic held-out 指标	数值
EF MAE	7.271
EF RMSE	9.603
EF 相关系数	0.647
低 EF 准确率	0.770
低 EF 精确率	0.479
低 EF 召回率	0.515
低 EF F1	0.496

EchoNet-Dynamic held-out 指标	数值
低 EF AUC	0.764




图 4. V5 EchoNet-Dynamic 校准层 held-out 指标。

Benchmark 设计与现有方案比较

EchoBench v1 是项目级 benchmark，而不是单脚本 smoke test。它包含单例交互、离线批量和常驻 server 三类场景。本次主报告使用离线批量完整证据、离线批量 12 帧代表抽样和 GGUF server smoke。性能测量思路参考 MLPerf 对离线、客户端和服务端场景的拆分，但本报告不是 MLPerf 官方提交结果（MLCommons, n.d.-a, n.d.-b）。

现有公开心超 AI 方案中，EchoNet-Dynamic 聚焦 EF 与左室功能，CAMUS 聚焦 2D 心超分割（Leclerc et al., 2019; Ouyang et al., 2020）。CardioConsult V5 的差异化在于多格式输入、B-mode 与 Color Doppler 代理特征、动图兼容、层级病症输出和本地离线 Gemma4 4B GGUF 中文报告生成。

成本模型与工程取舍

V5 的成本结构主要是一次性硬件和模型文件成本，运行时不需要按病例调用云 API。完整证据场景按平均 3.76 秒/例估算，规则流水线理论吞吐约 957 例/小时；12 帧场景按平均 2.56 秒/例估算，理论吞吐约 1,405 例/小时。真实 UI 使用会受人工选文件、磁盘读取、DICOM 解码和 GGUF 文本生成影响，因此演示吞吐应按更保守数值估计。

端到端大型视频模型可能在 EF 或分割任务上更强，但会带来 GPU/NPU 依赖、模型体积、训练时间和移动端迁移成本。V5 选择小模型校准和规则融合，是为了确保超声设备旁的普通 PC 可跑、移动端后续可迁移，并且每条诊断都有特征证据和规则路径可追踪。

限制与下一步

- 本地 60 例测试集规模有限，且来自授权本地数据，不是公开多中心盲法验证集。
- 报告链接标签是当前 benchmark 的金标准，但不是 2-3 位超声专家独立盲评后的共识标签。
- TR 在本批数据中全为阳性，PR 和 severe 标签样本不足，不能做有效结论。
- EchoNet-Dynamic 只增强 A4C B-mode 心功能相关任务，不提供瓣膜反流分级监督。
- AR、RWMA 和左房扩大在 12 帧抽样下降明显，未来必须增强切面识别、动图分割和标签平衡。

安全边界

本系统仅用于医学教学、算法演示和基层参考，不是医疗器械输出，不作为正式临床诊断、治疗建议或医嘱。若患者存在胸痛、晕厥、明显呼吸困难、低血压、发绀或急性心衰表现，应直接进入正式医疗流程并由有资质医师复核。

可复现信息

项目	值
V5 根目录	<V5_ROOT>
PC 应用目录	<V5_ROOT>\05_pc_v5
完整证据 run	runs\echobench_20260604_114319

项目	值
12 帧 run	runs\echobench_20260604_114016
EchoNet 训练报告	training\echonet_v5\training_report.json
R 图表脚本	reports\make_benchmark_figures.R

参考文献

- FDA, Health Canada, & Medicines and Healthcare products Regulatory Agency. (2021). Good machine learning practice for medical device development: Guiding principles. <https://www.gov.uk/government/publications/good-machine-learning-practice-for-medical-device-development-guiding-principles>
- ggml-org. (n.d.). GGUF file format - llama.cpp. Retrieved June 4, 2026, from <https://www.mintlify.com/ggml-org/llama.cpp/concepts/gguf-format>
- Google AI for Developers. (n.d.). Get started with Gemma models. Retrieved June 4, 2026, from https://ai.google.dev/gemma/docs/get_started
- Lang, R. M., Badano, L. P., Mor-Avi, V., Afilalo, J., Armstrong, A., Ernande, L., Flachskampf, F. A., Foster, E., Goldstein, S. A., Kuznetsova, T., Lancellotti, P., Muraru, D., Picard, M. H., Rietzschel, E. R., Rudski, L., Spencer, K. T., Tsang, W., & Voigt, J.-U. (2015). Recommendations for cardiac chamber quantification by echocardiography in adults: An update from the American Society of Echocardiography and the European Association of Cardiovascular Imaging. *Journal of the American Society of Echocardiography*, 28(1), 1-39.e14. <https://doi.org/10.1016/j.echo.2014.10.003>
- Leclerc, S., Smistad, E., Pedrosa, J., Ostvik, A., Cervenansky, F., Espinosa, F., Espeland, T., Berg, E. A. R., Jodoin, P.-M., Grenier, T., Lartzien, C., Dhooge, J., Lovstakken, L., Bernard, O., & Grenier, T. (2019). Deep learning for segmentation using an open large-scale dataset in 2D echocardiography. *IEEE Transactions on Medical Imaging*, 38(9), 2198-2210. <https://doi.org/10.1109/TMI.2019.2900516>
- MLCommons. (n.d.-a). MLPerf Client. Retrieved June 4, 2026, from <https://mlcommons.org/benchmarks/client/>
- MLCommons. (n.d.-b). MLPerf Inference benchmarks. Retrieved June 4, 2026, from <https://docs.mlcommons.org/inference/>
- MLCommons. (n.d.-c). MedPerf: An open benchmarking platform for medical artificial intelligence using federated evaluation. Retrieved June 4, 2026, from <https://github.com/mlcommons/medperf>
- OpenAI. (2025). Introducing HealthBench. <https://openai.com/index/healthbench/>

- Ouyang, D., He, B., Ghorbani, A., Yuan, N., Ebinger, J., Langlotz, C. P., Heidenreich, P. A., Harrington, R. A., Liang, D. H., Ashley, E. A., & Zou, J. Y. (2020). Video-based AI for beat-to-beat assessment of cardiac function. *Nature*, 580(7802), 252-256. <https://doi.org/10.1038/s41586-020-2145-8>
- Zoghbi, W. A., Adams, D., Bonow, R. O., Enriquez-Sarano, M., Foster, E., Grayburn, P. A., Hahn, R. T., Han, Y., Hung, J., Lang, R. M., Little, S. H., Shah, D. J., Shernan, S., Thavendiranathan, P., Thomas, J. D., & Weissman, N. J. (2017). Recommendations for noninvasive evaluation of native valvular regurgitation: A report from the American Society of Echocardiography developed in collaboration with the Society for Cardiovascular Magnetic Resonance. *Journal of the American Society of Echocardiography*, 30(4), 303-371. <https://doi.org/10.1016/j.echo.2017.01.007>